

Royaume du Maroc
Ministère de l'Industrie et du Commerce

Centre Marocain de Recherches Polytechniques et d'Innovation (CMRPI)
Espace Maroc Cyberconfiance (EMC)

RAPPORT DE PROJET DE FIN D'ANNÉE

Chatbot IA multilingue d'assistance aux victimes de cyberviolences

Système conversationnel RAG en français, arabe et darija marocaine

Réalisé par :

Salma SAID
Mohamed TAMZIRT

Filière Data & AI Engineering

Encadré par :

M. Anass BENTALEB (Intelligence Artificielle)
Mme Fadwa BELAOUS (Psychologie)

Période : 1^{er} juillet — 30 août 2026

Année universitaire 2025–2026

Remerciements

À compléter : Rédiger les remerciements : encadrants (M. Bentaleb, Mme Belaous), équipe du CMR-PI/EMC, établissement, et toute personne ayant contribué à la validation du contenu psychologique et juridique.

Résumé

Les cyberviolences constituent au Maroc un phénomène en expansion dont les victimes peinent à identifier les démarches à entreprendre, en particulier lorsque la barrière linguistique et le poids culturel de la *hchouma* (la honte) dissuadent la prise de parole. Ce projet propose un assistant conversationnel fondé sur une architecture *Retrieval-Augmented Generation* (RAG), capable de dialoguer en français, en arabe standard et en darija marocaine — y compris en *arabizi*, la darija écrite en caractères latins.

Le système repose sur une base de connaissances vérifiée de **57 documents** (droit marocain, procédures de signalement, prévention, soutien psychologique) et **64 paires questions-réponses** validées, indexées en **820 vecteurs** multilingues. Un protocole d'urgence court-circuite le modèle de langage lorsqu'un danger immédiat est détecté et renvoie directement les numéros officiels, garantissant une réponse instantanée et déterministe dans les situations critiques. L'interface web adapte sa direction d'écriture (RTL) et son vocabulaire à la langue choisie.

La solution est validée par **317 tests automatisés** et déployée sur une infrastructure gratuite (Hugging Face Spaces et Vercel).

Mots-clés : cyberviolence, RAG, LLM, multilinguisme, darija, accessibilité, FastAPI, React, ChromaDB, Gemini.

Abstract

Cyberviolence is a growing concern in Morocco, and victims often struggle to identify the steps available to them — especially when language barriers and the cultural weight of *hchouma* (shame) discourage them from speaking up. This project delivers a conversational assistant built on a Retrieval-Augmented Generation (RAG) architecture, able to converse in French, Modern Standard Arabic and Moroccan Darija, including *Arabizi* (Darija written in Latin script).

The system draws on a curated knowledge base of **57 documents** covering Moroccan law, reporting procedures, prevention and psychological support, plus **64 validated question-answer pairs**, indexed as **820** multilingual vectors. A safety protocol bypasses the language model whenever immediate danger is detected and returns official emergency numbers directly, guaranteeing an instant, deterministic response in critical situations. The web interface adapts its writing direction (RTL) and vocabulary to the selected language. The solution is covered by **317 automated tests** and deployed on free-tier infrastructure.

Keywords : cyberviolence, RAG, LLM, multilingualism, Darija, accessibility, FastAPI, React, ChromaDB, Gemini.

Table des matières

Remerciements	2
Résumé	3
Abstract	4
Introduction générale	8
1 Contexte général du projet	9
1.1 Organisme d'accueil : le CMRPI	9
1.2 Problématique	9
1.3 Objectifs	9
1.4 Méthodologie de travail	9
2 Étude de l'existant et analyse des besoins	11
2.1 Analyse des solutions existantes	11
2.2 Besoins fonctionnels	11
2.3 Besoins non fonctionnels	11
3 Conception	12
3.1 Architecture générale	12
3.2 Le pipeline RAG	12
3.3 Base de connaissances	13
3.4 Traitement du multilinguisme	13
3.4.1 Un angle mort de sécurité : l'urgence en arabizi	13
3.5 Accompagnement psychologique	14
4 Réalisation	15
4.1 Choix technologiques	15
4.2 API	15
4.3 Interface utilisateur	15
4.4 Accessibilité	19
4.5 Sécurité applicative	19
5 Tests, évaluation et déploiement	20
5.1 Stratégie de tests	20
5.2 Mesures	20
5.3 Évaluation qualitative des réponses	20
5.4 Déploiement	21
Conclusion et perspectives	22
Bibliographie et webographie	23
A Annexes	24
A.1 Numéros d'urgence intégrés	24
A.2 Structure du dépôt	24
A.3 Exemple de réponse en situation d'urgence	24

Table des figures

3.1	Architecture générale du système. Le chemin d’urgence (en rouge) court-circuite la recherche documentaire et le modèle de langage.	12
4.1	Écran d’accueil : présentation du service, avis de confidentialité, rappel des limites et suggestions d’entrée en matière	16
4.2	Conversation en français : réponse structurée et sources documentaires consultées, dépliabiles à la demande	16
4.3	Protocole d’urgence : panneau annoncé aux lecteurs d’écran, numéros officiels directement appelables, traitement visuel volontairement sobre	17
4.4	Interface en arabe : inversion complète de la mise en page (RTL), tandis que les nombres et les identifiants latins conservent leur sens de lecture	17
4.5	Affichage mobile : navigation repliée et zone de saisie toujours accessible	18

Liste des tableaux

1.1	Découpage du projet en sprints	10
2.1	Exigences non fonctionnelles et traduction technique	11
3.1	Composition de la base de connaissances	13
4.1	Pile technologique et justification des choix	15
4.2	Points d'entrée de l'API	15
5.1	Répartition des tests automatisés	20
5.2	Indicateurs mesurés sur le dépôt	20
A.1	Dispositifs d'urgence et de signalement intégrés au système	24

Introduction générale

À compléter : Développer l'introduction (environ une page) en articulant : contexte national des cyberviolences, mission du CMRPI et de l'EMC, problématique retenue, objectifs du projet, et annonce du plan du rapport.

Le présent rapport s'organise en cinq chapitres. Le chapitre 1 présente l'organisme d'accueil et le cadre du projet. Le chapitre 2 analyse les solutions existantes et formalise les besoins. Le chapitre 3 détaille la conception de l'architecture et de la base de connaissances. Le chapitre 4 décrit la réalisation technique. Enfin, le chapitre 5 expose la stratégie de tests, les résultats obtenus et le déploiement.

Chapitre 1

Contexte général du projet

1.1 Organisme d'accueil : le CMRPI

À compléter : Présenter le CMRPI : missions, positionnement institutionnel, campagne nationale de lutte contre la cybercriminalité, et le rôle de l'Espace Maroc Cyberconfiance (EMC) au sein du centre.

1.2 Problématique

Les victimes de cyberviolences au Maroc font face à trois obstacles cumulés :

1. **Un déficit d'information.** Les recours (signalement en ligne, dépôt de plainte, conservation des preuves) sont dispersés entre plusieurs dispositifs et mal connus.
2. **Une barrière linguistique.** Une part importante de la population s'exprime spontanément en darija, à l'écrit comme à l'oral, y compris en caractères latins (*arabizi*). Les dispositifs existants ne traitent généralement que le français et l'arabe standard.
3. **Un frein culturel.** La *hchouma* — la honte — dissuade de nombreuses victimes de parler, en particulier pour les atteintes à caractère sexuel. Un dispositif anonyme et non jugeant lève une partie de ce frein.

1.3 Objectifs

- Concevoir un assistant conversationnel accessible **sans compte et sans identification**, disponible en français, arabe standard et darija.
- Fonder les réponses sur une **base documentaire vérifiée** plutôt que sur la seule mémoire d'un modèle de langage, afin de limiter les hallucinations sur des sujets juridiques.
- Garantir une **réponse immédiate et déterministe** en situation de danger vital.
- Adapter le discours au **profil** de l'utilisateur (victime, parent, enseignant, témoin, jeune) et à son **état émotionnel**.

1.4 Méthodologie de travail

Le projet a suivi une démarche agile organisée en quatre sprints de deux semaines, documentée dans le répertoire `plan/` du dépôt.

À compléter : Ajouter le diagramme de Gantt (disponible sous forme Mermaid dans `project_guide.md`) et préciser la répartition des tâches entre les deux étudiants.

Sprint	Semaines	Objet
Sprint 1	S1-S2	Analyse de l'existant, scénarios conversationnels, bases de connaissances FR et AR
Sprint 2	S3-S4	Pipeline RAG, API FastAPI, intégration du LLM et des prompts
Sprint 3	S5-S6	Interface React, module multilingue, intégration end-to-end
Sprint 4	S7-S8	Tests, évaluation, optimisation et déploiement

Table 1.1 – Découpage du projet en sprints

Chapitre 2

Étude de l'existant et analyse des besoins

2.1 Analyse des solutions existantes

Trois dispositifs de référence ont été étudiés : le chatbot EMC en version bêta, la plateforme *eVigilance* de la DGSN et le portail *cyberconfiance.ma*. L'analyse complète figure dans `docs/analyse_existant.md`.

À compléter : Reprendre ici la synthèse comparative et la matrice SWOT de `docs/analyse_existant.md` (sections 5 et 6), et conclure sur les axes d'amélioration retenus.

2.2 Besoins fonctionnels

- Dialogue multilingue avec détection automatique de la langue du message.
- Réponses fondées sur une base documentaire citée en sources.
- Détection des situations d'urgence et affichage des numéros officiels.
- Adaptation au profil de l'utilisateur et à sa détresse émotionnelle.
- Historique de conversation à l'échelle d'une session.
- Recueil d'un retour de satisfaction sur chaque réponse.

2.3 Besoins non fonctionnels

Exigence	Traduction technique
Confidentialité	Aucun compte requis ; le contenu des conversations n'est ni journalisé en production ni persisté sur le poste du visiteur
Accessibilité	Conformité WCAG 2.2 niveau AA, navigation clavier complète, support des lecteurs d'écran
Multilinguisme	Interface FR/AR/darija, direction d'écriture RTL, polices embarquées
Robustesse	Numéros d'urgence affichés même en cas d'indisponibilité du service
Performance	Réponse inférieure à 5 secondes hors démarrage à froid
Sécurité	Assainissement des contenus générés, liste blanche de schémas d'URL, endpoints d'administration authentifiés

Table 2.1 – Exigences non fonctionnelles et traduction technique

Chapitre 3

Conception

3.1 Architecture générale

L'architecture retenue sépare l'interface, l'orchestration métier et le pipeline de génération augmentée par la recherche (figure 3.1).




Figure 3.1 – Architecture générale du système. Le chemin d'urgence (en rouge) court-circuite la recherche documentaire et le modèle de langage.

3.2 Le pipeline RAG

Le choix d'une architecture RAG répond directement à la nature du domaine : les réponses portent sur des textes de loi et des procédures officielles, où une hallucination du modèle serait inacceptable. Le pipeline se décompose en cinq étapes.

1. **Ingestion.** Les documents Markdown sont enrichis de métadonnées (langue, catégorie, mots-clés) puis découpés en fragments de 500 caractères avec 50 caractères de recouvrement, en respectant la structure des titres.
2. **Vectorisation.** Le modèle `paraphrase-multilingual-MiniLM-L12-v2` (384 dimensions) projette français et arabe dans un espace sémantique commun.

3. **Recherche.** La recherche est filtrée par langue, puis les candidats sont reclassés par recoupement lexical avec les mots-clés curés ; un repli inter-langue est prévu lorsque la langue demandée ne donne aucun résultat.
4. **Augmentation.** Les fragments retenus sont injectés dans un prompt système spécifique à la langue, complété d'indications liées au profil détecté.
5. **Génération.** Le modèle Gemini produit la réponse, qui subit ensuite des vérifications déterministes (présence des recours de signalement, amorce de soutien émotionnel).

Décision de conception : la sécurité ne dépend pas du LLM

Lorsqu'un message contient un marqueur de danger immédiat, la réponse est **entièrement pré-écrite** et renvoyée sans appel au modèle de langage. Ce choix élimine trois risques simultanément : la latence du réseau, une éventuelle indisponibilité de l'API, et toute variation de formulation sur une information vitale.

3.3 Base de connaissances

Catégorie	Français	Arabe
Fiches pratiques	9	6
Juridique	6	3
Prévention	6	4
Rapports internationaux	4	4
Psychologie	3	3
Ressources	3	3
FAQ	2	1
Total documents	33	24
Paires questions-réponses	32	32

Table 3.1 – Composition de la base de connaissances

Le volet juridique couvre les lois **103-13** (violences faites aux femmes), **07-03** (atteintes aux systèmes de traitement automatisé des données), **09-08** (protection des données personnelles), **27-14** (traite des êtres humains) et **88-13** (presse et édition).

3.4 Traitement du multilinguisme

La détection de langue est **déterministe** plutôt que probabiliste : tout texte en caractères arabes est routé vers le pipeline arabe ; un texte latin est considéré comme français, sauf présence d'un marqueur arabizi complet (**wach**, **bghit**, **n9der**, **kifach**...). Ce choix évite les erreurs des détecteurs statistiques sur les messages courts, fréquents en situation de détresse.

À compléter : Justifier plus longuement le choix d'une détection déterministe et présenter la liste des marqueurs (voir `backend/services/language_service.py`).

3.4.1 Un angle mort de sécurité : l'urgence en arabizi

Le multilinguisme ne se joue pas seulement au niveau de la langue de réponse. La campagne de tests a révélé un défaut de sécurité que la seule détection de langue ne pouvait pas rattraper : les mots-clés de danger vital n'existaient qu'en caractères arabes. Écrite en caractères arabes, la phrase « je veux mourir » déclenchait bien le protocole d'urgence ; sa transcription latine **bghit**

nmot — le même aveu d'idées suicidaires, tapé de la façon la plus courante sur un téléphone marocain — ne le déclenchait pas. Une victime écrivant en arabizi ne recevait aucun numéro d'urgence.

Trois passes ont été ajoutées à `detect_urgency()` :

1. la liste de mots-clés correspondant à la langue détectée, comme auparavant ;
2. la liste *française* lorsque le message est en caractères latins mais routé vers le pipeline arabe — les locuteurs de darija alternent constamment avec le français, et « **wach kayn chi urgence** » doit compter ;
3. une liste arabizi de 38 entrées, couvrant les variantes orthographiques, puisque l'arabizi n'a pas d'orthographe normalisée.

Ces entrées sont comparées **sur des limites de mots** et non par sous-chaîne : un jeton court comme **nmot** ne doit jamais se déclencher à l'intérieur d'un mot français. Le compromis est assumé dans un sens précis — un faux positif affiche des numéros d'urgence à quelqu'un qui n'en avait pas besoin, un faux négatif laisse une personne suicidaire sans réponse. La suite de tests verrouille les deux côtés : seize formulations qui doivent alerter, dix questions ordinaires qui ne le doivent pas.

3.5 Accompagnement psychologique

Sur recommandation de Mme Belaous, le système intègre une *météo des émotions*, des messages de validation et de normalisation, ainsi que des exercices guidés pas à pas (respiration carrée 4-4-4-4, ancrage sensoriel 5-4-3-2-1). Lorsqu'une détresse émotionnelle est détectée, le soutien précède systématiquement les conseils techniques et les démarches de signalement.

À compléter : Détailler les cinq personas et les parcours associés à partir de `docs/scenarios_conversationnels.md`.

Chapitre 4

Réalisation

4.1 Choix technologiques

Couche	Technologie	Justification
Backend	FastAPI (Python 3.11)	Typage natif, documentation OpenAPI automatique, asynchrone
Pipeline RAG	LangChain	Abstractions d'ingestion et de recherche éprouvées
Base vectorielle	ChromaDB	Persistance locale, filtrage par métadonnées, sans serveur dédié
Embeddings	MiniLM multilingue	384 dimensions, FR et AR dans un espace commun, exécutable sur CPU
LLM	Google Gemini	Bonnes performances en darija, encapsulé derrière un fournisseur interchangeable
Frontend	React 19 + TypeScript	Typage strict de bout en bout, écosystème de tests mature
Style	Tailwind CSS v4	Jetons de conception centralisés, propriétés logiques pour le RTL

Table 4.1 – Pile technologique et justification des choix

4.2 API

L'API expose sept points d'entrée documentés automatiquement (Swagger).

Méthode	Route	Rôle
GET	/api/health	État de l'API, du RAG et du LLM
POST	/api/chat	Envoi d'un message, réponse augmentée
POST	/api/chat/session	Création d'une session
GET	/api/chat/history/{id}	Historique d'une session
POST	/api/chat/feedback	Retour de satisfaction (1–5)
GET	/api/admin/sessions	Sessions actives (<i>authentifié</i>)
DELETE	/api/admin/sessions/{id}	Suppression d'une session (<i>authentifié</i>)

Table 4.2 – Points d'entrée de l'API

4.3 Interface utilisateur

L'interface privilégie le calme et la lisibilité : palette sobre, typographie généreuse, absence d'animation superflue. La figure 4.1 présente l'écran d'accueil.




Figure 4.1 – Écran d'accueil : présentation du service, avis de confidentialité, rappel des limites et suggestions d'entrée en matière




Figure 4.2 – Conversation en français : réponse structurée et sources documentaires consultées, déplaçables à la demande




Figure 4.3 – Protocole d’urgence : panneau annoncé aux lecteurs d’écran, numéros officiels directement appelables, traitement visuel volontairement sobre




Figure 4.4 – Interface en arabe : inversion complète de la mise en page (RTL), tandis que les nombres et les identifiants latins conservent leur sens de lecture




Figure 4.5 – Affichage mobile : navigation repliée et zone de saisie toujours accessible

4.4 Accessibilité

L'interface vise le niveau AA de la norme WCAG 2.2 : contrastes vérifiés automatiquement sur les jetons de conception, navigation clavier complète, zones d'annonce distinctes pour les réponses ordinaires (`aria-live="polite"`) et pour les urgences (`role="alert"`), respect de `prefers-reduced-motion`.

4.5 Sécurité applicative

- Assainissement systématique du Markdown généré ; le HTML brut n'est jamais interprété.
- Liste blanche de schémas d'URL (`http`, `https`, `mailto`, `tel`).
- Limitation de débit à 30 requêtes par minute et par adresse IP.
- Endpoints d'administration désactivés par défaut et protégés par clé.
- Aucune persistance du contenu des conversations côté navigateur.

Chapitre 5

Tests, évaluation et déploiement

5.1 Stratégie de tests

Suite	Tests	Portée
Backend (pytest)	170	Ingestion, recherche, chaîne RAG, détection de langue, sessions, schémas, authentification
Frontend (Vitest)	100	Client API, rendu, sécurité du Markdown, RTL, accessibilité (axe-core)
End-to-end (Playwright)	25	Parcours complets sur navigateur, mobile et bureau
Scripts (pytest)	22	Acquisition et normalisation des images
Total	317	

Table 5.1 – Répartition des tests automatisés

5.2 Mesures

Indicateur	Valeur mesurée
Vecteurs indexés (français / arabe)	820 (535 / 285)
Documents ingérés	122
Latence de recherche vectorielle (médiane)	19 ms
Latence du protocole d'urgence	sans appel LLM
Code backend (hors tests)	3 246 lignes
Code frontend (hors tests)	3 417 lignes
Code de test	3 150 lignes
Bundle frontend au chargement (gzip)	149 Ko
Rendu Markdown (chargé à la demande, gzip)	48 Ko
Tests automatisés (backend / front / e2e / scripts)	348

Table 5.2 – Indicateurs mesurés sur le dépôt

À compléter : Compléter par la latence de bout en bout mesurée en production (POST /api/chat) sur un échantillon de requêtes réelles, et par les résultats de la campagne d'évaluation qualitative des réponses.

5.3 Évaluation qualitative des réponses

À compléter : Reprendre et actualiser docs/evaluation_llm.md : la matrice des 20 scénarios doit être ré-exécutée, d'une part parce que le modèle configuré a changé, d'autre part parce que l'index arabe s'est enrichi de 72 fragments supplémentaires.

5.4 Déploiement

Le backend est déployé sur *Hugging Face Spaces* (SDK Docker) et le frontend sur *Vercel*, deux offres gratuites. L'image du backend embarque le modèle d'embeddings et construit la base vectorielle *pendant la construction*, ce qui garantit un démarrage déterministe. Le frontend relaie les appels `/api` vers le backend, ce qui maintient l'ensemble sur une même origine et permet de conserver une politique de sécurité de contenu stricte.

La procédure complète figure dans `docs/guide_déploiement.md`.

À compléter : Insérer l'URL publique de démonstration une fois le déploiement effectué.

Conclusion et perspectives

À compléter : Rédiger la conclusion : rappel des objectifs, bilan de ce qui a été réalisé, apports personnels et compétences acquises, difficultés rencontrées.

Perspectives

1. **Mesure du rappel en arabizi.** La détection d'urgence couvre désormais la darija en caractères latins (voir §3.4.1), mais sur la base d'une liste de variantes orthographiques établie à la main. Une campagne d'annotation sur des messages réels permettrait de mesurer le rappel effectif et de repérer les formulations manquantes.
2. **Persistance des sessions.** Le passage à un magasin Redis permettrait de survivre aux redémarrages et de répartir la charge sur plusieurs instances.
3. **Embeddings distants.** Le recours à une API d'embeddings allégerait considérablement l'image de déploiement, au prix d'un recalibrage du seuil de similarité.
4. **Enrichissement de la base arabe.** Le corpus arabe reste moins fourni que le corpus français (285 vecteurs contre 535).
5. **Évaluation avec des utilisateurs réels**, encadrée sur le plan éthique, afin de mesurer l'utilité perçue du dispositif.

Bibliographie et webographie

- [1] Espace Maroc Cyberconfiance (EMC) — <https://www.cyberconfiance.ma>
- [2] Plateforme nationale de signalement eVigilance — <https://evigilance.ma>
- [3] Royaume du Maroc, *Loi n° 103-13 relative à la lutte contre les violences faites aux femmes.*
- [4] Royaume du Maroc, *Loi n° 07-03 complétant le code pénal en ce qui concerne les infractions relatives aux systèmes de traitement automatisé des données.*
- [5] Royaume du Maroc, *Loi n° 09-08 relative à la protection des personnes physiques à l'égard du traitement des données à caractère personnel.*
- [6] P. Lewis *et al.*, *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*, NeurIPS, 2020.
- [7] N. Reimers, I. Gurevych, *Sentence-BERT : Sentence Embeddings using Siamese BERT-Networks*, EMNLP, 2019.
- [8] W3C, *Web Content Accessibility Guidelines (WCAG) 2.2*, 2023.

À compléter : Compléter avec les rapports UNICEF, UNESCO, OMS et Conseil de l'Europe effectivement exploités dans la base de connaissances.

Annexe A

Annexes

A.1 Numéros d’urgence intégrés

Service	Numéro	Portée
Police secours	19	Zones urbaines, 24h/24
Gendarmerie Royale	177	Zones rurales, 24h/24
Protection Civile	15	Urgence médicale
ONDE	2511	Enfants en danger, gratuit
EMC-Helpline	—	https://www.cyberconfiance.ma
eVigilance	—	https://evigilance.ma/fr/signaler

Table A.1 – Dispositifs d’urgence et de signalement intégrés au système

A.2 Structure du dépôt

Listing A.1 – Organisation des sources

```
1 backend/      API FastAPI et pipeline RAG
2   api/        routes, schemas, middlewares, securite
3   llm/        fournisseur Gemini
4   prompts/    prompts systeme FR et AR
5   rag/        ingestion, embeddings, retriever, chain
6   services/   langue, sessions, orchestration
7 frontend/     interface React + TypeScript
8 data/         base de connaissances et base vectorielle
9 docs/         livrables, analyses, guide de deploiment
10 plan/        planification des quatre sprints
```

A.3 Exemple de réponse en situation d’urgence

Listing A.2 – Réponse renvoyée sans appel au modèle de langage

```
1 Si vous etes en danger immediat, appelez les autorites tout de suite :
2 - Police : 19 (en ville)
3 - Gendarmerie Royale : 177 (en zone rurale)
4 - Protection Civile : 15 (urgence medicale)
5 - ONDE : 2511 (si la victime est un enfant)
6 - EMC-Helpline : cyberconfiance.ma (en ligne, gratuit)
7
8 Vous n’etes pas seul(e). L’aide est disponible 24h/24.
```